

Univerzitet u Novom Sadu
Fakultet tehničkih nauka

Softverski algoritmi u sistemima automatskog upravljanja

Predikcija preostalog korisnog veka (RUL) turboventilatorskog mlaznog motora

NASA C-MAPSS FD001 dataset

Anja Stojković
RA 150/2023

Novi Sad, 2026

Sadržaj

1. Uvod.....	6
2. Opis dataseta.....	6
2.1 NASA C-MAPSS dataset.....	6
2.2 Karakteristike FD001 podskupa.....	6
2.3 Opis atributa.....	6
2.4 Princip prikupljanja podataka.....	7
3. Eksplorativna analiza podataka.....	7
3.1 Analiza RUL distribucije.....	7
3.2 Korelaciona analiza.....	8
3.3 Analiza vremenskog trenda senzora.....	9
4. Priprema podataka.....	10
4.1 Učitavanje i inicijalna inspekcija.....	10
4.2 Izračunavanje RUL za trening skup.....	10
4.3 Uklanjanje konstantnih senzora.....	10
4.4 Normalizacija — MinMaxScaler.....	10
4.5 Ograničavanje RUL na 125 (Piecwise-Linear Degradation).....	11
4.6 Feature engineering — pokretni proseci.....	11
4.7 Podela podataka bez curenja.....	11
5. Opis korišćenih modela.....	11
5.1 Baseline model.....	11
5.2 XGBoost (eXtreme Gradient Boosting).....	11
5.3 Random Forest.....	12
5.4 Podešavanje hiperparametara — RandomizedSearchCV.....	12
5.5 Odabir najznačajnijih atributa.....	12
6. Metrike evaluacije.....	13
6.1 RMSE (Root Mean Squared Error).....	13
6.2 NASA Score (asimetrična funkcija gubitka).....	10
7. Rezultati.....	13
7.1 Pregled rezultata na test skupu.....	13
7.2 Interpretacija rezultata.....	14
8. Analiza važnosti atributa.....	15
9. Diskusija rezultata.....	16
9.1 Poređenje XGBoost vs Random Forest.....	16
9.2 Uticaj podešavanja hiperparametara.....	16
9.3 Metodološka napomena o podeli podataka.....	16

10. Zaključak	16
11. Literatura	17

1. Uvod

Predmet projekta je predikcija preostalog korisnog veka (**RUL-Remaining Useful Life**) turboventilatorskog mlaznog motora, izražena brojem preostalih ciklusa (letova) do kvara. Problem pripada domenu prediktivnog održavanja, gde se motor servisira na osnovu procene stvarnog stanja iz senzorskih podataka umesto po fiksnim vremenskim intervalima.

Cilj je razvoj regresionog modela mašinskog učenja koji na osnovu istorijskih senzorskih merenja i operativnih podešavanja daje numeričku procenu preostalog radnog veka motora. Kao podloga koristi se NASA C-MAPSS FD001 dataset, a uspešnost modela meri se RMSE i NASA Score metrikama.

2. Opis dataseta

2.1 NASA C-MAPSS dataset

NASA C-MAPSS (Commercial Modular Aero-Propulsion System Simulation) dataset razvijen je u istraživačkom centru Glenn pomoću naprednog simulatora koji verno replicira termodinamičke procese velikih turboventilatorskih motora (poput serije CFM56 na Boeing 737 i Airbus A320). Sastoji se od četiri podskupa (FD001-FD004) koji se razlikuju po broju operativnih režima i modova kvara. U projektu se koristi FD001, najjednostavniji i najčešće korišćeni scenario.

2.2 Karakteristike FD001 podskupa

Karakteristika	Vrednost
Broj motora u trening skupu	100
Broj motora u test skupu	100
Broj operativnih režima	1 (nivo mora)
Mod kvara	Degradacija HPC
Ukupno redova (train)	20.631
Ukupno redova (test)	13.096
Broj atributa	26

2.3 Opis atributa

Identifikacioni atributi: **unit** (jedinstveni ID motora, 1-100) i **ciklus** (redni broj leta i vremenska osa degradacije; svaki motor počinje od ciklusa 1 do trenutka kvara).

Operativna podešavanja: **op1** (visina leta), **op2** (brzina maha) i **op3** (ugao nagiba usisnog ventilatora). Pošto FD001 ima samo jedan operativni režim (nivo mora), podešavanja praktično

ne variraju: op3 je potpuno konstantan (standardna devijacija 0) i uklanja se u fazi čišćenja, dok op1 i op2 imaju zanemarljivu varijaciju ($\text{std} > 0$) i zadržavaju se.

Senzorska merenja (s1-s21). Informativni senzori i njihove fizičke veličine:

Senzor	Fizička veličina
s2	Temperatura na izlazu ventilatora ($^{\circ}\text{R}$)
s3	Temperatura na izlazu kompresora niskog pritiska ($^{\circ}\text{R}$)
s4	Temperatura na izlazu kompresora visokog pritiska ($^{\circ}\text{R}$)
s6	Temperatura na izlazu turbine niskog pritiska ($^{\circ}\text{R}$)
s7	Pritisak na izlazu ventilatora (psia)
s8	Fizička brzina ventilatora (rpm)
s9	Fizička brzina jezgra motora (rpm)
s11	Pritisak na izlazu kompresora visokog pritiska (psia)
s12	Odnos goriva i vazduha u sagorevnoj komori
s13	Korigovana brzina ventilatora (rpm)
s14	Korigovana brzina jezgra (rpm)
s15	Odnos zaobilaznog vazduha (bypass ratio)
s17	Statički pritisak u turbini visokog pritiska (psia)
s20	Odnos protoka vazduha ventilatora
s21	Temperatura na izlazu turbine visokog pritiska ($^{\circ}\text{R}$)

Senzori s1, s10, s18 i s19 imaju konstantne vrednosti u FD001 i uklanjaju se iz analize.

2.4 Princip prikupljanja podataka

Trening skup prati svaki motor po principu *run-to-failure*: podaci počinju od prvog ciklusa (motor ispravan) i teku kroz uzastopne cikluse do potpunog otkazivanja. Test skup obuhvata iste motore, ali je vremenski niz namerno prekinut u nasumičnom trenutku pre kvara. Zadatak modela je da na osnovu dostupnih podataka predvidi koliko ciklusa preostaje do otkazivanja.

3. Eksplorativna analiza podataka


3.1 Analiza RUL distribucije

Pre ograničavanja, životni vek motora u trening skupu kreće se između 128 i 362 ciklusa (prosečno oko 206), što znači da neki motori otkazu više nego dvostruko brže od drugih. Pošto


se RUL svakog reda računa kao razlika između maksimalnog i trenutnog ciklusa, sirove RUL vrednosti dostižu i preko 360.

Distribucija ovih vrednosti nije ravnomerna. Nakon ograničavanja na 125, svi redovi sa RUL većim od 125 sažimaju se u jednu vrednost. Zbog toga se na histogramu javlja izrazit „šiljak“ na 125, dok je u intervalu od 0 do 125 raspored znatno ravnomerniji.

Ovaj oblik distribucije direktna je posledica prirode podataka: svaki motor počinje rad u ispravnom stanju i provede dug period bez znakova degradacije, a tek u poslednjih ~125 ciklusa ulazi u fazu merljivog propadanja, koja je ravnomerno raspoređena. Takav obrazac karakterističan je za FD001 podskup.



Slika 1. Opadanje RUL kroz cikluse za prvih 5 motora.




Slika 2. Distribucija RUL vrednosti u trening skupu (cap na 125).

3.2 Korelaciona analiza

Pearsonova korelacija između senzora i RUL-a otkriva jasne obrasce degradacije.

- **Negativna korelacija** (vrednost raste kako motor stari): s11 (pritisak HPC, najjača korelacija), s4 (temperatura HPC), s15 (odnos zaobilaznog vazduha).
- **Pozitivna korelacija** (vrednost opada kako motor stari): s7 (pritisak ventilatora), s12 (odnos goriva i vazduha), s20 (protok vazduha).


Ovo potvrđuje fizičku logiku degradacije kompresora visokog pritiska: kako kompresor gubi efikasnost, pritisak koji generiše raste (kompenzacioni efekat), dok protok i ukupna efikasnost sistema opadaju.



Slika 3. Korelacija senzora sa RUL vrednošću.

3.3 Analiza vremenskog trenda senzora

Vizualizacija ključnih senzora kroz cikluse (motor 1) pokazuje da signali nisu monoton prisutan je šum između pojedinačnih merenja, ali ukupni trend degradacije ostaje jasno vidljiv. Upravo taj šum motiviše primenu pokretnih proseka u fazi pripreme podataka.



Slika 4. Promena ključnih senzora kroz cikluse (motor 1).

4. Priprema podataka

4.1 Učitavanje i inicijalna inspekcija

Dataset se učitava iz tekstualnih fajlova bez zaglavlja (separator je razmak), pa se kolone ručno definišu. Odmah se proverava postojanje nedostajućih vrednosti C-MAPSS je simuliran i potpun, bez NaN vrednosti, ali je provera standardna praksa u ML pipeline-u.

4.2 Izračunavanje RUL za trening skup

Za svaki motor maksimalni broj ciklusa predstavlja trenutak kvara (RUL = 0). RUL svakog reda računa se po formuli:

$$RUL = \max_ciklus(motor) - trenutni_ciklus$$

Tako motor na prvom ciklusu ima maksimalni RUL, a na poslednjem RUL = 0.

4.3 Uklanjanje konstantnih senzora

Senzori sa standardnom devijacijom nula nemaju informativnu vrednost; identifikuju se programski i uklanjaju iz oba skupa (train i test moraju imati iste attribute). Uklonjeni su: op3, s1, s10, s18 i s19, ukupno 5 atributa.

4.4 Normalizacija - MinMaxScaler

Senzori imaju različite fizičke opsege (temperatura u stotinama °R, pritisci u jediničnom opsegu psia). Bez normalizacije bi senzori sa numerički većim vrednostima dobili neopravdano veću težinu. MinMaxScaler prevodi sve vrednosti u opseg [0, 1]:

$$x_{norm} = (x - x_{min}) / (x_{max} - x_{min})$$

Scaler se trenira (fit) isključivo na trening podacima, a na test skup se primenjuju naučeni parametri. Time test skup ostaje nepoznat modelu tokom cele pripreme, čime se simulira realna primena.

4.5 Ograničavanje RUL na 125 (Piecewise-Linear Degradation)

U ranim ciklusima motor ne pokazuje znake degradacije, signali su stabilni i nema razlike između motora sa RUL = 300 i RUL = 200, što otežava učenje. Standardno rešenje u literaturi za C-MAPSS je postavljanje gornje granice RUL-a na 125 ciklusa: sve veće vrednosti tretiraju se kao 125. Tako model uči da razlikuje samo kritičnih poslednjih 125 ciklusa, period operativno relevantan za planiranje servisiranja.

4.6 Feature engineering - pokretni proseci

Merenja između uzastopnih ciklusa su zašumljena. Pokretni prosek (rolling average) poslednjih N vrednosti glača šum i ističe pravi trend. Odabran je prozor od 5 ciklusa (window=5) kao balans između glačanja i kašnjenja signala. Za svaki senzor dodaje se kolona sa sufiksom _roll5; parametar min_periods=1 rešava prve cikluse bez 5 prethodnih merenja. Ovom operacijom broj atributa se praktično udvostručuje.

4.7 Podela podataka bez curenja

Podela se vrši po motorima, a ne nasumično po redovima. Susedni ciklusi istog motora imaju gotovo identične vrednosti senzora uz RUL koji se razlikuje za samo 1; nasumična podela bi ih rasporedila u različite skupove i model bi faktički „video“ odgovor pre validacije, dajući lažno dobre metrike. Poslednjih 20 motora (ID 81-100) čini validacioni, a prvih 80 (ID 1-80) trening skup. Za test skup uzima se poslednji poznati red svakog motora, tačno kao u realnoj primeni.

5. Opis korišćenih modela

5.1 Baseline model

Baseline za svaki motor predviđa konstantnu vrednost, prosečan RUL iz trening skupa — bez obzira na senzorske podatke. To je statistički najjednostavniji model koji ne „uči“ ništa. Njegova svrha je referentna tačka: ako ML model ne pobedi baseline, znači da ne uspeva da izvuče korisne obrasce iz podataka.

5.2 XGBoost (eXtreme Gradient Boosting)

XGBoost je ansambl zasnovan na gradijentnom pojačavanju: iterativno gradi sekvencu stabala odluke, gde svako novo stablo uči na greškama prethodnih. Prednosti za ovaj problem: efikasno rukovanje tabelarnim podacima visoke dimenzionalnosti, ugrađena L1/L2 regularizacija protiv overfitting-a, automatska procena važnosti atributa i brz, paralelizovan trening.

Korišćeni hiperparametri:

Hiperparametar	Vrednost	Objašnjenje
n_estimators	200	Broj stabala u ansamblu
max_depth	6	Maksimalna dubina stabla; kontroliše kompleksnost
learning_rate	0.05	Korak učenja; manja vrednost = stabilnije, sporije
random_state	42	Fiksno seme za reproducibilnost
n_jobs	-1	Paralelizacija na svim jezgrima

5.3 Random Forest

Random Forest gradi veliki broj nezavisnih stabala, svako na nasumičnom podskupu podataka (bootstrap) i atributa; finalna predikcija je prosek svih stabala. Ovo „averaging“ smanjuje varijansu i poboljšava generalizaciju. Za razliku od XGBoost-a, stabla se grade paralelno i nezavisno, bez iterativnog ispravljanja grešaka.

Korišćeni hiperparametri:

Hiperparametar	Vrednost	Objašnjenje
n_estimators	200	Broj stabala u ansamblu
max_depth	10	Ograničena dubina sprečava overfitting
random_state	42	Fiksno seme za reproducibilnost
n_jobs	-1	Paralelni trening na svim jezgrima

5.4 Podešavanje hiperparametara - RandomizedSearchCV

Umesto iscrpne pretrage (Grid Search), koja bi za 5 hiperparametara sa po 4 vrednosti dala $4^5 = 1024$ kombinacije, korišćen je Randomized Search: nasumično se bira 20 kombinacija, a svaka se ocenjuje 3-fold cross-validacijom (trening skup se deli na tri dela, model se trenira na dva i evaluira na trećem, rotacijom; konačna ocena je prosek). Pretraženi prostor:

- n_estimators: {100, 200, 300, 400}
- max_depth: {4, 6, 8, 10}
- learning_rate: {0.01, 0.05, 0.1, 0.2}
- subsample: {0.7, 0.8, 0.9, 1.0}
- colsample_bytree: {0.7, 0.8, 0.9, 1.0}

5.5 Odabir najznačajnijih atributa

Feature importance u XGBoost-u meri koliko se svaki atribut koristi za podelu u stablima i koliko ta podela smanjuje grešku. Na osnovu te mere odabrano je top 10 atributa i treniran novi XGBoost samo na njima, da bi se proverilo može li kompaktniji model dostići pun model.

6. Metrike evaluacije

6.1 RMSE (Root Mean Squared Error)

$$RMSE = \sqrt{(1/n) \cdot \sum (\hat{y}_i - y_i)^2}$$

Gde je $\hat{y}_i$ predviđeni, a y_i stvarni RUL motora i . RMSE penalizuje velika odstupanja kvadratno greška od 20 ciklusa kažnjava se 4 puta više od greške od 10. Niža vrednost znači precizniji model, jedinica je ista kao ciljna promenljiva (broj ciklusa).

6.2 NASA Score (asimetrična funkcija gubitka)

$$S = \sum [e^{-(d_i/13)} - 1 \text{ ako } d_i < 0; e^{(d_i/10)} - 1 \text{ ako } d_i \geq 0]$$

Gde je $d_i = \hat{y}_i - y_i$ razlika između predviđenog i stvarnog RUL-a. Asimetričnost:


- **Rano predviđanje ($d < 0$)**- konzervativna procena, motor se ranije šalje na servis; kazna raste sporije.
- **Kasno predviđanje ($d > 0$)**- motor ostaje duže u upotrebi nego što treba; kazna raste brže.

Ova asimetrija odražava realnost avioindustrije: propuštanje nadolazećeg kvara opasnije je od preuranjenog servisa. Niži NASA Score znači bolji model.

7. Rezultati

7.1 Pregled rezultata na test skupu

Model	RMSE (test)	NASA Score (test)	Poboljšanje RMSE vs Baseline
Baseline	42.85	30932	—
Random Forest	18.46	1023	56.9 %
XGBoost	18.05	1024	57.9 %
XGBoost (top 10 atributa)	18.34	1114	57.2 %
Optimizovani XGBoost	18.35	1014	57.2 %




Slika 5. Poređenje modela po RMSE i NASA Score metrici.

7.2 Interpretacija rezultata

Baseline model, koji ignoriše senzorski kontekst, postiže RMSE od 42,85 ciklusa i izrazito visok NASA Score (30.932). Oba ML modela ga ubedljivo nadmašuju: XGBoost je najbolji sa RMSE 18,05 (poboljšanje od 57,9 % u odnosu na baseline), neznatno ispred Random Forest-a (18,46). Po NASA Score-u dva modela su praktično izjednačena (1.024 naspram 1.023).

Optimizovani XGBoost u ovom slučaju nije poboljšao rezultat RMSE 18,35 je čak blago lošiji od podrazumevane konfiguracije (18,05). To sugerise da su default hiperparametri XGBoost-a već blizu optimalnih za ovaj problem, a moguće je i da nasumična cross-validacija tokom pretrage daje blago optimistične procene koje se ne prenose na test skup.

XGBoost sa samo 10 atributa daje skoro isti rezultat (RMSE 18,34) kao pun model (18,05) ostalih ~30 atributa uglavnom je nosilo informaciju koja je već sadržana u tih 10.




Slika 6. Predviđene vs stvarne RUL vrednosti (XGBoost i Random Forest).

Svaka tačka je jedan testni motor. Na x-osi je stvarni RUL, na y-osi ono što je model predvideo. Crvena isprekidana linija je „idealna linija“ kad bi predviđanje bilo savršeno, sve tačke bi ležale

tačno na njoj. Što su tačke bliže liniji, model je precizniji. Kod oba modela tačke lepo prate dijagonalu, što potvrđuje dobru tačnost;

- **Tačka iznad linije** → model precenjuje RUL (kaže da motoru preostaje više nego što stvarno preostaje) to je *kasno* predviđanje, opasnije.
- **Tačka ispod linije** → model potcenjuje (konzervativno, šalje motor ranije na servis).



Slika 7. Stvarni vs predviđeni RUL kroz cikluse za testne motore.


Za četiri pojedinačna motora prikazana je njihova degradacija u vremenu. Plava linija je stvarni RUL koji ravnomerno opada kako motor radi (svaki ciklus = -1). Crvena isprekidana vodoravna linija je **jedna brojka**, RUL koji je model predvideo na poslednjem poznatom ciklusu (crvena tačka na kraju plave linije).

Drugim rečima, ovde se vidi koliko se modelova konačna procena (crvena) poklapa sa stvarnim preostalim vekom u tom trenutku.

8. Analiza važnosti atributa

Dijagram važnosti atributa pokazuje koji senzori najviše utiču na predikciju RUL-a. Svih 10 najznačajnijih atributa su pokretni proseci (`_roll5` varijante), pri čemu prednjače `s4_roll5` i `s11_roll5` senzori vezani za kompresor visokog pritiska. Ovo je dvostruka potvrda: fizički je konzistentno sa simuliranim modom kvara (degradacija HPC), a istovremeno snažno opravdava

korak feature engineering-a glačanje šuma pokretnim prosekom poboljšava odnos signal/šum i čini atribute informativnijim od sirovih merenja.



Slika 8. Važnost atributa za XGBoost i Random Forest (top 15).

9. Diskusija rezultata

9.1 Poređenje XGBoost vs Random Forest

XGBoost je nadmašio Random Forest na FD001 datasetu, što je u skladu s literaturom. Razlozi: gradijentno pojačavanje iterativno ispravlja greške prethodnih stabala ugrađena regularizacija efikasnije kontroliše overfitting, a nelinearne zavisnosti u RUL problemu gradijentno pojačavanje uspešnije modelira. Razlika je ipak skromna (18,10 vs 18,46).

9.2 Uticaj podešavanja hiperparametara

Suprotno čestom očekivanju, podešavanje hiperparametara ovde nije donelo poboljšanje. To pokazuje da su default vrednosti XGBoost-a robusne za ovaj tip tabelarnog problema i da prostor za dobitak optimizacijom nije uvek značajan.

9.3 Metodološka napomena o podeli podataka

Podela po motorima (umesto nasumično po redovima) osigurava da validacione metrike realno odražavaju generalizaciju na potpuno nove motore. Nasumična podela dovela bi do curenja podataka, jer bi model kroz susedne cikluse istog motora posredno „video“ deo odgovora.

10. Zaključak

Projekat je demonstrirao primenu mašinskog učenja za prediktivno održavanje u avioindustriji. Razvijeni pipeline obuhvata sve ključne faze od eksplorativne analize, preko pripreme i feature engineering-a, do treninga, optimizacije i evaluacije. Glavni zaključci:

- Senzorski podaci FD001 sadrže dovoljno informacija za preciznu predikciju RUL-a oba modela ubedljivo nadmašuju baseline (~58 % manji RMSE).
- XGBoost je najbolji model po RMSE i NASA Score metrici, neznatno ispred Random Forest-a.
- Pokretni proseci su ključan doprinos: svih 10 najvažnijih atributa su _roll5 varijante.
- Model sa samo 10 atributa dostiže pun model značajan deo atributa je redundantan, što je relevantno za brzu inferencu.
- Identifikovani ključni senzori (s4, s11 i njihove _roll5 varijante) fizički su konzistentni s degradacijom kompresora visokog pritiska, što potvrđuje interpretabilnost modela.

Glavno ograničenje je korišćenje simuliranih podataka; realni motori imaju složenije obrasce degradacije, varijacije kvaliteta goriva i različite operativne profile koje simulator ne replicira u potpunosti. Ipak, razvijena metodologija direktno je primenljiva na realne senzorske podatke uz odgovarajuća podešavanja.

11. Literatura

- [1] Saxena, A., Goebel, K., Simon, D., & Eklund, N. (2008). Damage propagation modeling for aircraft engine run-to-failure simulation. IEEE International Conference on Prognostics and Health Management.
- [2] Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining.
- [3] Breiman, L. (2001). Random forests. Machine Learning, 45(1), 5–32.
- [4] NASA C-MAPSS Dataset. <https://data.nasa.gov/dataset/C-MAPSS-Aircraft-Engine-Simulator-Data>